スケジューリング

田浦健次朗

CPU スケジューリング

- OS の重要な仕事：スレッドに CPU[1] を割り当てる
- 基本：かわりばんこ (round robin)
- ただし, 文字通り存在するすべてのスレッド ($> 1{,}000$ 個は当たり前) に均等時間ずつ, ではない

[1] 「仮想コア」が正確な言い方だが

スレッドの状態

- OS は以下の 3 つの状態を区別している
  - 実行中 (running)
  - 実行可能 (runnable, active)
  - 中断中 (blocked, suspended)

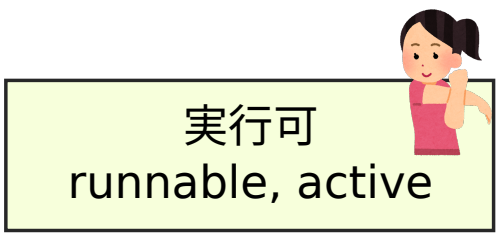

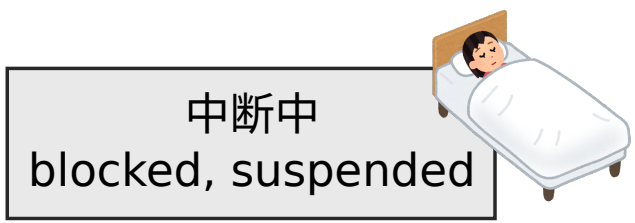

スレッドの状態

- OS は以下の 3 つの状態を区別している
  - 実行中 (running)
  - 実行可能 (runnable, active)
  - 中断中 (blocked, suspended)

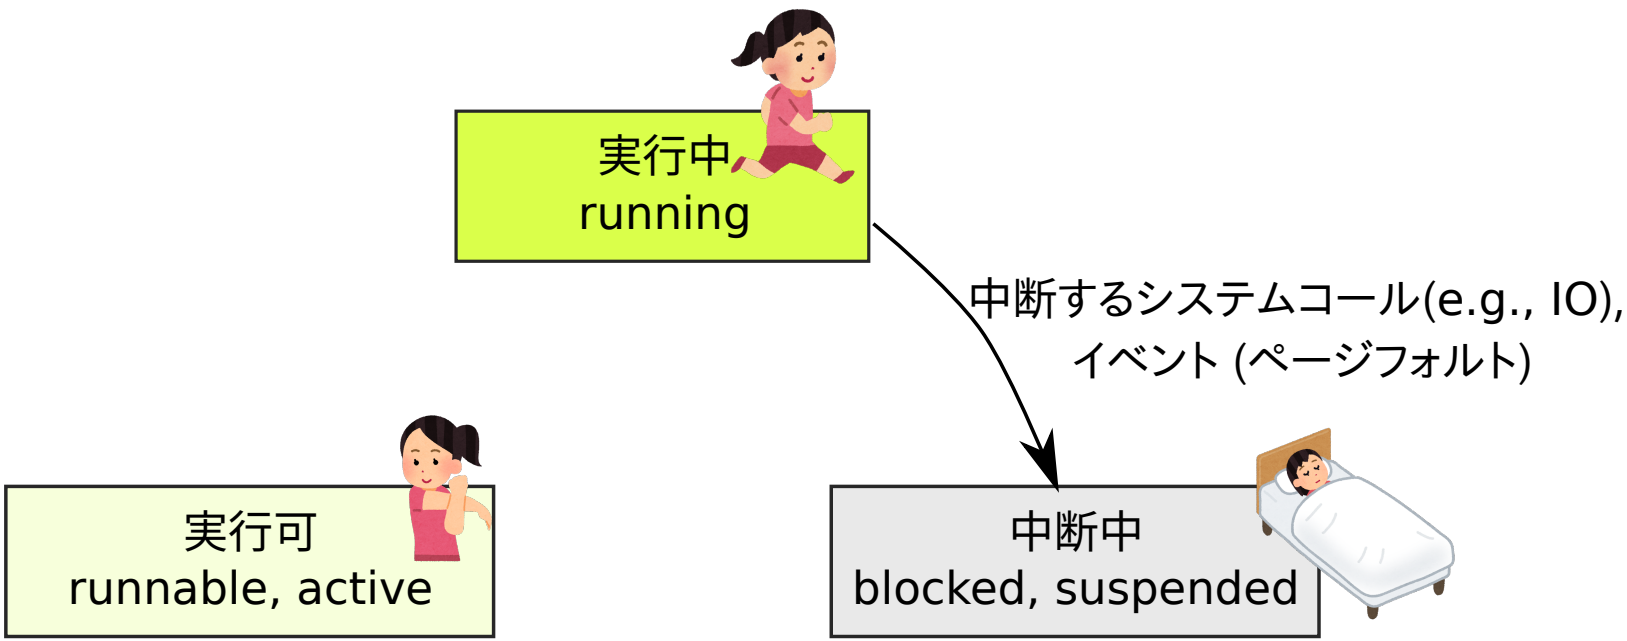

スレッドの状態

- OS は以下の 3 つの状態を区別している
  - 実行中 (running)
  - 実行可能 (runnable, active)
  - 中断中 (blocked, suspended)

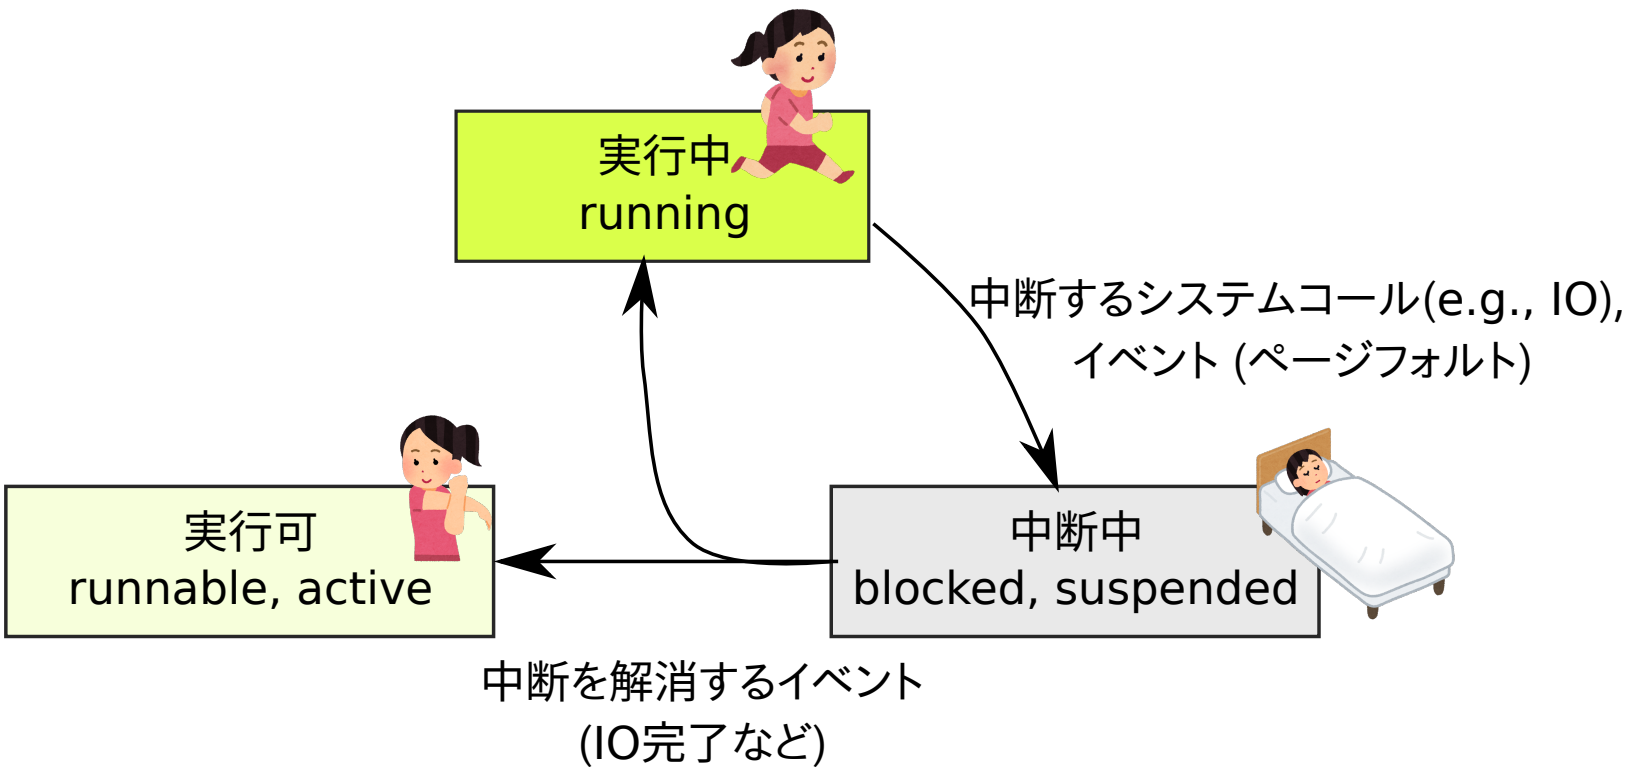

スレッドの状態

- OS は以下の 3 つの状態を区別している
  - 実行中 (running)
  - 実行可能 (runnable, active)
  - 中断中 (blocked, suspended)

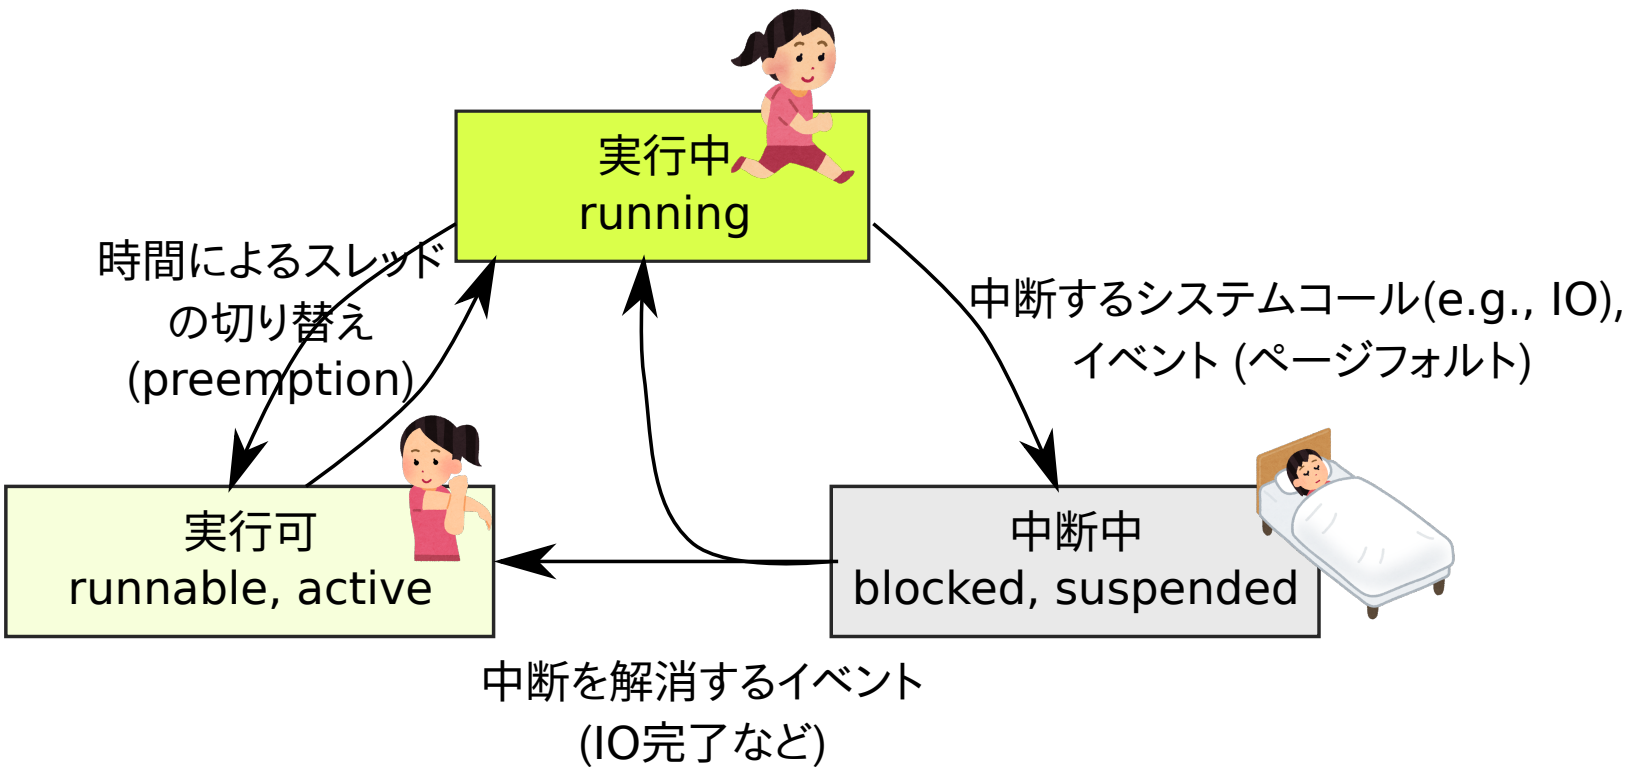

スレッドが中断する時の例

- OS が, 現在実行中のスレッドがこれ以上実行不能と判断する時
  - `read`, `recv` などブロッキング I/O で読むデータがない
  - `waitpid`, `pthread_join` などで, 子プロセス・スレッドが終了していない
  - `pthread_mutex_lock`, `pthread_cond_wait` など同期 API で同期が成立していない (次週以降)
  - sleep, usleep, nanosleep など休眠 API
  - ページフォルト (次週以降) で I/O が発生
- OS は, 現在実行中のスレッドから, 別のスレッドに切り替える (コンテクストスイッチ)

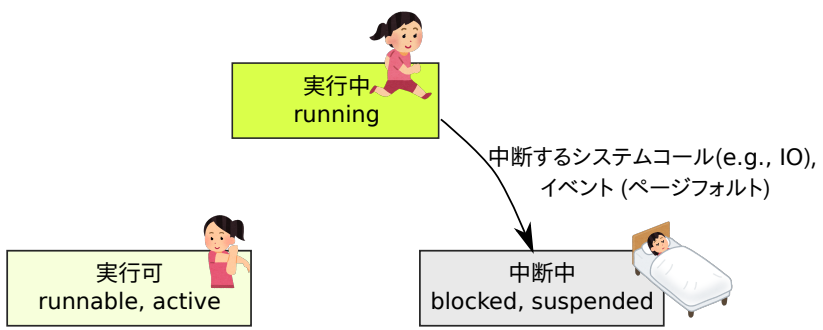

ほとんどのスレッドは中断している

- `ps auxww`, `top` コマンドの `STAT` 欄
  - R 実行中または実行可
  - S 中断中 (割り込み可能)
  - D 中断中 (割り込み不可能)
  - その他 ...
- S と D の違いはあまり気にしなくて良い. D はそれほど見かけない
- まめ知識: Unix の load average (負荷平均) = R か D 状態にあるスレッド数 ≈ R 状態にあるスレッド数 (の最近何分かの平均)

スレッドはどこで中断しているかの観察

- デバッガ (gdb) で実行中のプロセスをデバッグ可能 (attach)

```
1 $ gdb
2 (gdb) attach pid
```

- 典型
  - poll, select, pselect (複数のファイルディスクリプタからの入力待ち)
  - read (ファイルディスクリプタからの入力待ち)

タスクキュー, ランキュー

- 実行中・実行可状態のスレッドを維持するデータ構造
  - 通常, 仮想コアごとに一つ
  - 「キュー」とは言うが FIFO とは限らない
- OS はスレッドを切り替える際, ランキュー中から, ある基準 (後述) に従って次のスレッドを選んで実行する

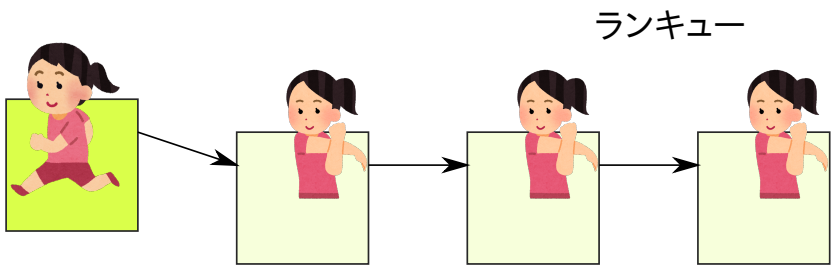

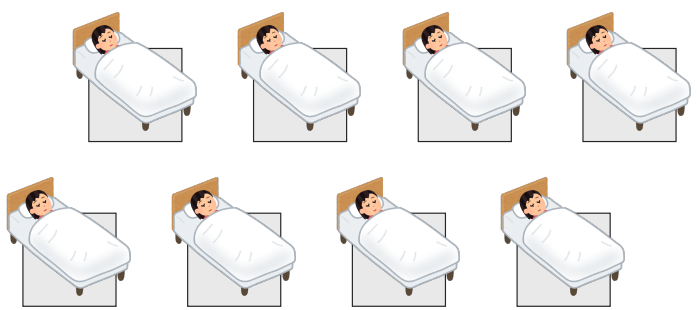

Preemption (横取り)

- スレッドが自発的に OS に制御を渡さない (なにもシステムコールを呼ばずに走り続けている) 状態でも, 強制的に制御を奪うこと (≡ preemption)
- preemption を行うスケジューラ ≡ preemptive なスケジューラ
- 今日の OS のスケジューラは事実上すべてが preemptive
- preemption を実現する仕組み: タイマ割り込み

割り込み, タイマ割り込み

生の CPU (仮想コア): 以下を繰り返す

```
while (1) {
    PC の指すアドレスから命令を読む
    命令を実行する (一部のレジスタが書き換わる, PC 含め)




}
```

注: PC = プログラムカウンタレジスタ

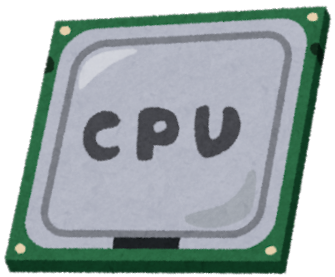

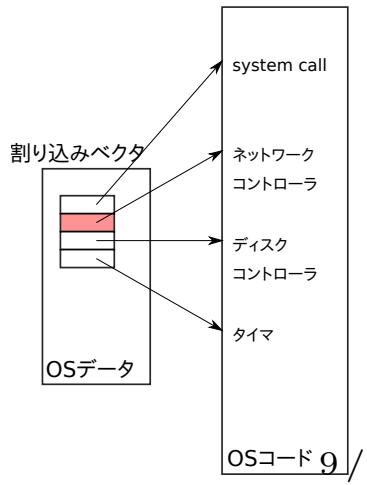

割り込み, タイマ割り込み

生の CPU (仮想コア): 以下を繰り返す

```
while (1) {
    PC の指すアドレスから命令を読む
    命令を実行する (一部のレジスタが書き換わる, PC 含め)
    if (割り込みが来た) {
        PC := 割り込みベクタ [割り込み番号];
    }
}
```

注: PC = プログラムカウンタレジスタ

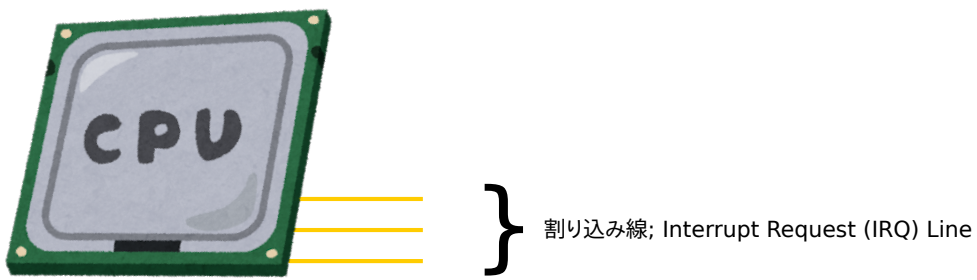

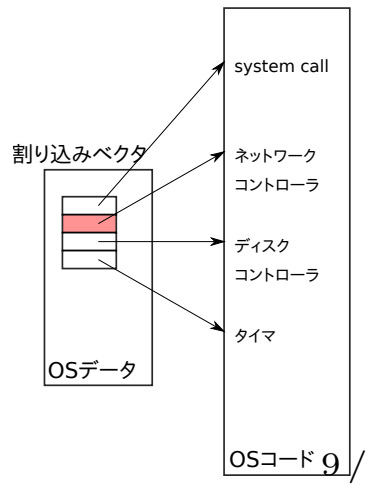

割り込み, タイマ割り込み

生の CPU (仮想コア): 以下を繰り返す

```
while (1) {
    PC の指すアドレスから命令を読む
    命令を実行する (一部のレジスタが書き換わる, PC 含め)
    if (割り込みが来た) {
        PC := 割り込みベクタ [割り込み番号];
    }
}
```

注: PC = プログラムカウンタレジスタ

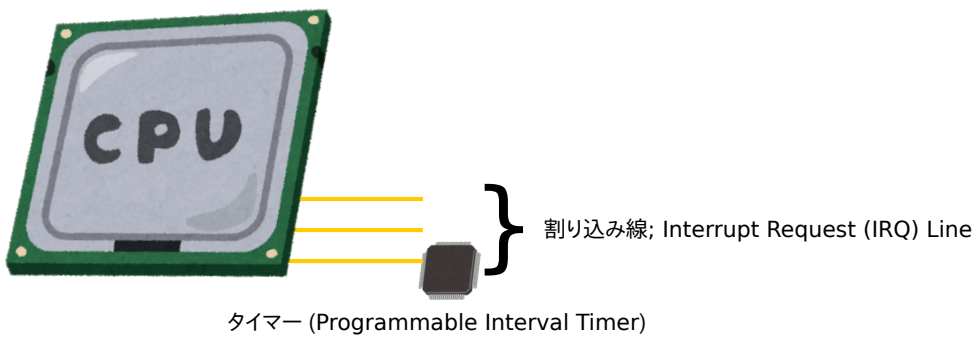

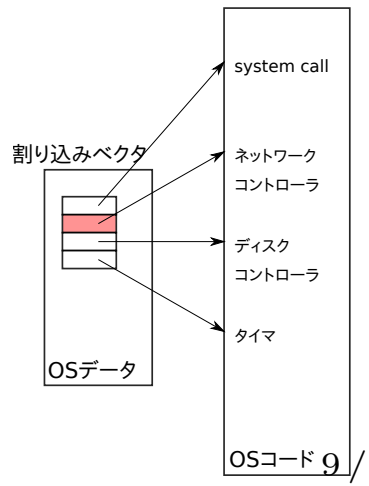

ランキューの動き

ランキューには実行可・実行中のスレッドが入っている

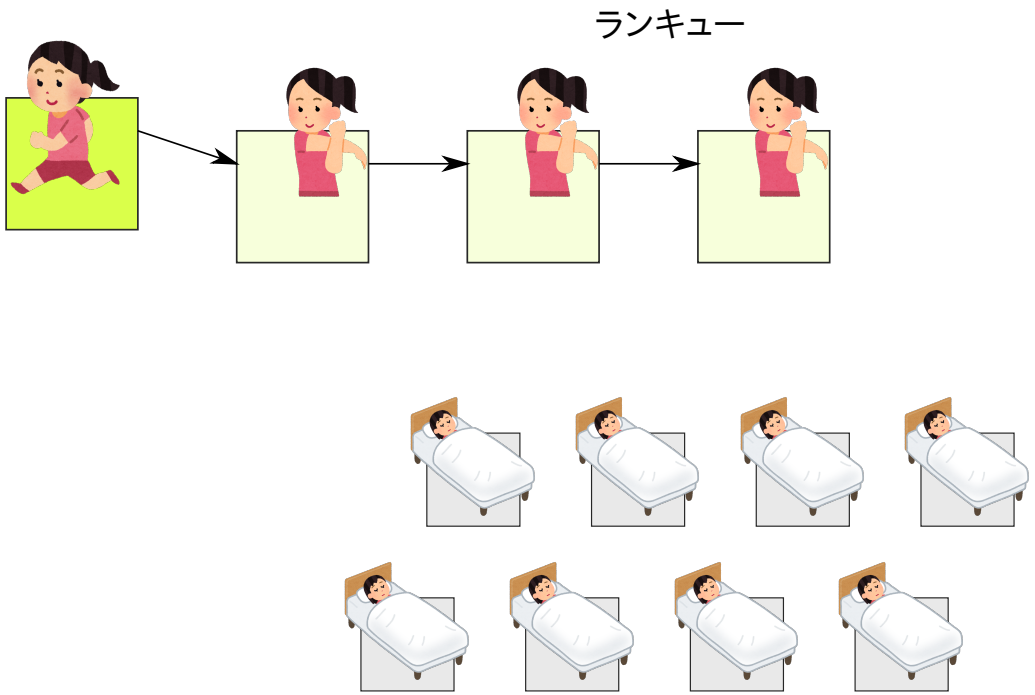

ランキューの動き

実行中のスレッドが中断 → ランキューから外れる

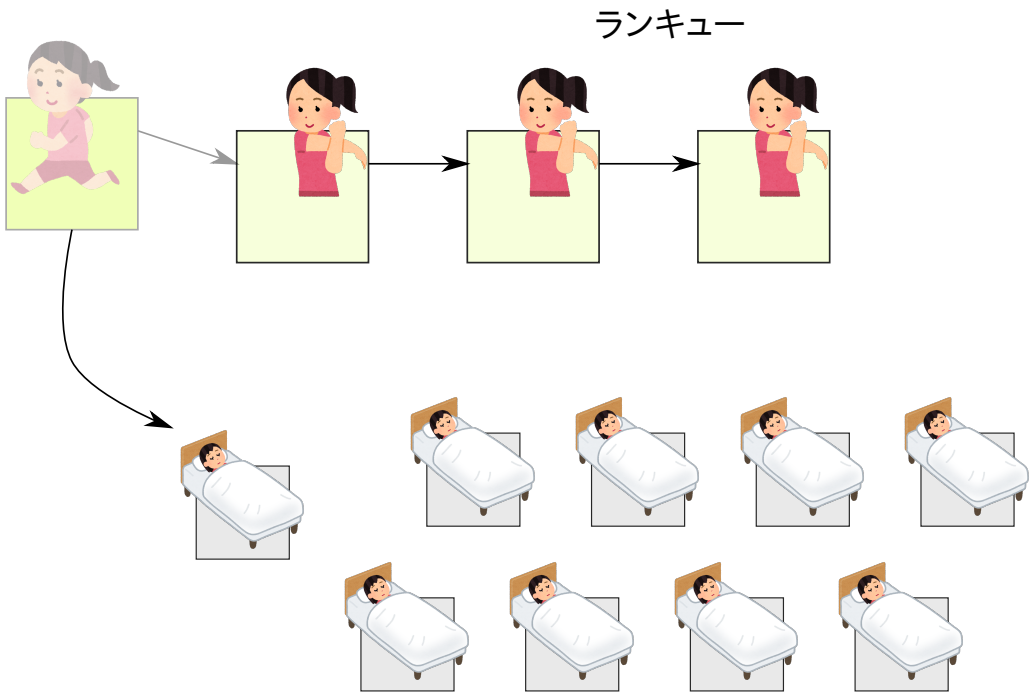

ランキューの動き

ランキューから次のスレッドが選ばれて実行される

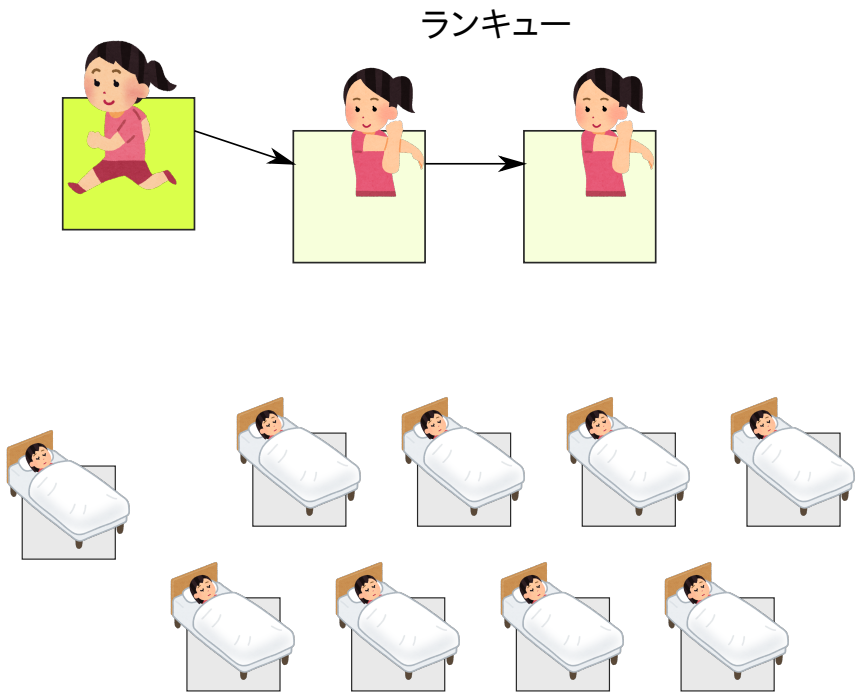

ランキューの動き

中断中のスレッドが再開 → ランキューに挿入される

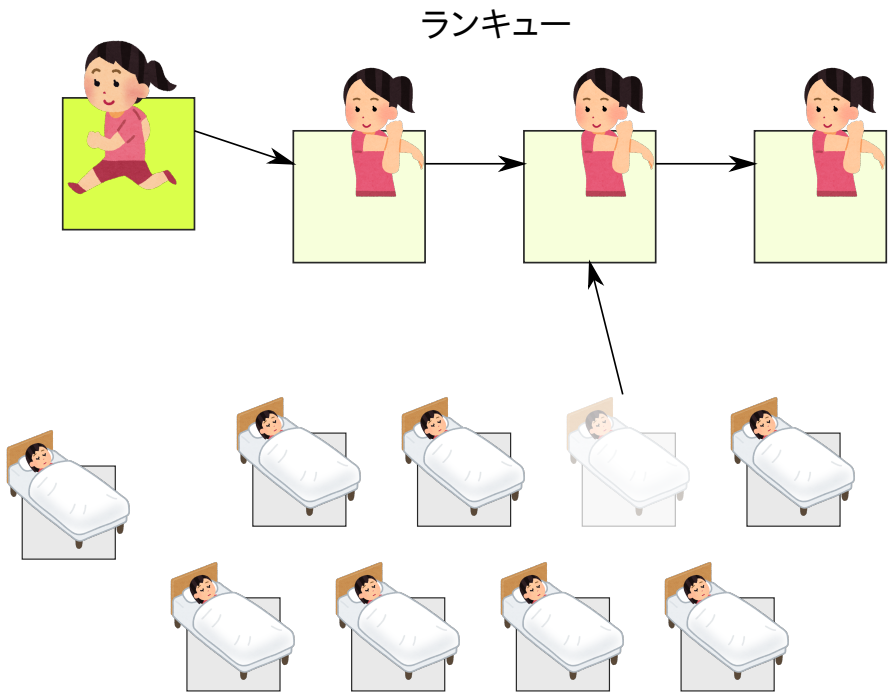

ランキューの動き

タイマ割り込み → 実行中のスレッドが十分な時間 (time quantum) を消費していたら, preemption

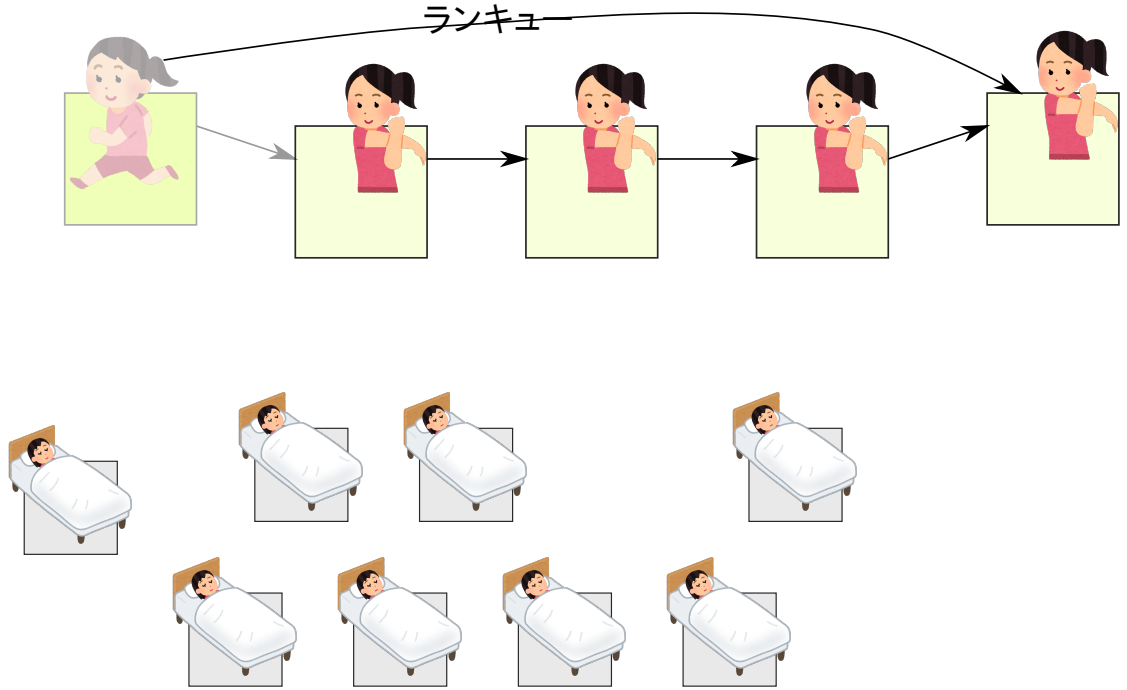

ランキューの動き

ランキューから次のスレッドが選ばれて実行される

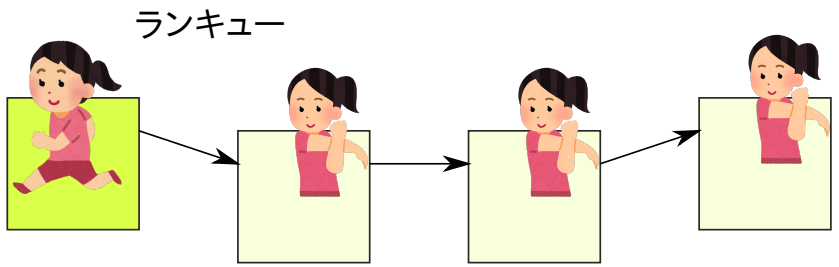

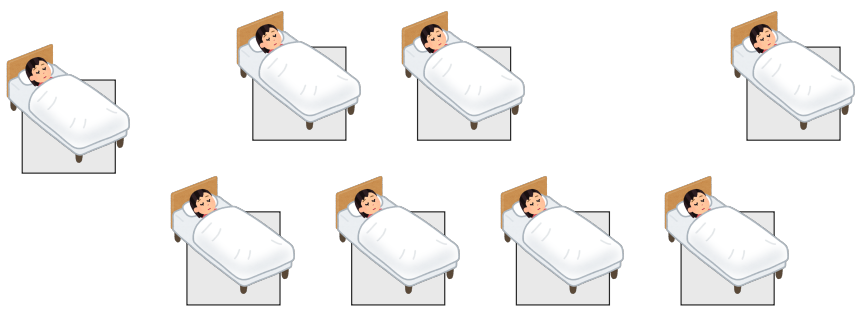

スレッド選択

- OS はスレッドを切り替える際, ランキュー中から, ある基準に従って次のスレッドを選んで実行する
- ある基準の例
  - Round Robin (純粋なかわりばんこ)
  - Linux Completely Fair Scheduler (CFS)

Round Robin

- ランキューが純粋な FIFO
- 中断から回復したらキューの末尾に入る
- 実行中のスレッドの time quantum が expire したら末尾に入る
- 次のスレッドを選ぶ際はキューの先頭が選ばれる

Round Robin の問題点

- **公平性:**
  - 「中断していた $\Longleftrightarrow$ CPU を使っていなかった」スレッドも,
  - 「preempt された $\Longleftrightarrow$ ずっと CPU を使っていた」スレッド

  も同じ扱い
- **対話的なプログラムの応答性:** 実行可のスレッドが多い (load average が高い) と, それに比例して, 「応答時間 = 中断状態から再開してから実行されるまでの時間」が長くなる

Linux Completely Fair Scheduler (CFS)

- Linux 2.6.23 以降のデフォルトスケジューラ
  - 各スレッドが「消費した合計 CPU 時間のようなもの (→ vruntime)」を管理
  - スレッド切り替え (実行中スレッドが中断した, 中断中スレッドが復帰した, タイマ割り込みがおきた, など) 時に, 実行可能スレッド中で vruntime が最小のスレッドを次に実行する
  - 注: ランキューを, vruntime の小さい順にスレッドが並ぶ優先度キューとすれば実現可能
- 効果
  - 長い目で見て, 各スレッドへの CPU 割当時間を均等にすることができる → 公平
  - しばらく中断していた (CPU を使っていなかった) スレッドが再開した時, その間実行されていたスレッドよりも vruntime が小さいことが期待される
    → 対話的スレッドの応答性が高い

vruntime

- 文字通り, 「vruntime = 割り当てた CPU 時間の合計」とするのは問題がある
  - 作られたばかりのスレッドの vruntime = 0 ⇒ すでに vruntime=10 秒のスレッドは 10 秒間待たされる?
  - 中断していたスレッドの vruntime は一切増えない ⇒ 10 秒間中断してから再開した時, その 10 秒間ずっと走っていたスレッドは 10 秒間待たされる?
- つまり「公平に CPU を割当る」と言っても, 「長時間に渡った合計が均等」が目標ではない (長時間中断していた分を無制限に「貯金」とされては困る)

vruntime 管理の実際

1. 生成時は親の vruntime を継承. 親スレッド A が子スレッド B を生成

$$B.\texttt{vruntime} = A.\texttt{vruntime}$$

2. タイマ割り込み, スレッド中断時に, 実行中だったスレッド T の vruntime を加算.

$$T.\texttt{vruntime} \texttt{ += } T \text{ が今回消費した CPU 時間}$$

3. スレッド T が中断から復帰する時は, T の vruntime が他の実行可・中スレッドよりも極端に小さくならないことを保証

$$T.\texttt{vruntime} = \max(T.\texttt{vruntime}, \min_{t\text{: 実行可}} t.\texttt{vruntime} - 20\ \text{ms})$$

複数コアがある場合

- ランキューは仮想コアごとにある
- それぞれの仮想コアがこれまで述べた方式でスレッドをスケジューリング
- それに加え, ランキューの長さ (各仮想コアで実行 { 可・中 } なスレッド数) が均等になるよう, 時折スレッドが移動する
  - ある仮想コアのランキューが空になったとき
  - preempt 時やシステムコールが呼ばれたとき